$\frac{du}{dt} = -u$, $u(0) = 1$.

$\hat{u}(t;\theta) = \sum_{i=1}^{3} v_i \tanh(w_i t + b_i) + c$

w_i 입력 가중치, b_i 은닉층 편향, v_i 출력가중치.
c 출력 편향.

$\theta = [w_1, w_2, w_3, b_1, b_2, b_3, v_1, v_2, v_3, c]$
학습해야 하는 모든 파라미터 의미
참고, 선형회귀. $\theta = [w, b]$.

미분방정식 만족 위해 시점망 시간에 대해 미분.

$\frac{d}{dt}\tanh(w_i t + b_i) = (1 - \tanh^2(w_i t + b_i)) w_i$

$\frac{d\hat{u}}{dt} = \sum_{i=1}^{3} v_i (1 - \tanh^2(w_i t + b_i)) w_i$

PDE Residual

$\frac{d}{dt}u + u = 0$, $R(t) = \frac{d\hat{u}}{dt} + \hat{u}$

Residual 이 모든 t에서 0에 가까운 신경망은 미분방정식을 만족.

Residual 이 전체 학습점에서 작아지도록 평균제곱 오차 (~~MSE~~ MSE)를 정의한다.

$L_{PDE} = \frac{1}{N}\sum_{i=1}^{N} R(t_i)^2$ 또 초기조건 추가한다.

$L_{IC} = (\hat{u}(0) - 1)^2$ 전체 loss를 정의

$L = L_{PDE} + L_{IC}$

Loss가 작아질수록 모든 신경망은 미분방정식과 초기조건을 동시에 만족한다.

$\frac{\partial L}{\partial \theta_i}$ 로 파라미터의 기울기를 구한다. (수치적 예제)

$\frac{\partial L}{\partial \theta_i} \approx \frac{L(\theta_i + \varepsilon) - L(\theta_i - \varepsilon)}{2\varepsilon}$

제시된 그라디언트로 모든 파라미터 갱신

$\theta^{(k+1)} = \theta^{(k)} - \eta \nabla_\theta L$

ibis

참고로 선형회귀의 업데이트 공식

$w \leftarrow w - \eta \frac{\partial L}{\partial w}$

$b \leftarrow b - \eta \frac{\partial L}{\partial b}$

요약. 전체과정

$t \rightarrow \hat{u}(t;\theta) \rightarrow \frac{d\hat{u}}{dt} \rightarrow R(t) \rightarrow L$
$\rightarrow \nabla_\theta L \rightarrow \theta_{new}$.

끝.